

ARQUITETURA DE REFERÊNCIA PARA MEMÓRIA ARTIFICIAL E MECANISMOS DE DECAIMENTO TEMPORAL PARA RAG

Desenho de Pesquisa — Mestrado Profissional em Computação Aplicada (PPGCA)

PESQUISADOR

Lucas Nascimento Aguiar

Mestrando em Computação Aplicada

ORIENTADOR

Prof. Dr. Rogério de Oliveira

PROGRAMA & INSTITUIÇÃO

PPGCA | Mestrado Profissional

Universidade Presbiteriana Mackenzie

ABORDAGEM METODOLÓGICA

Design Science Research (DSR)

POR QUÊ?	O QUÊ?	COMO?				
Contexto e Motivação Sistemas de RAG atuais tratam o conhecimento como atemporal e estático , usando similaridade vetorial para recuperação. Em interações que necessitam de conhecimento específico, essa abordagem resgata fatos obsoletos junto com os atuais, comprometendo a confiabilidade das respostas e a consistência contextual do sistema.	Estado da arte/prática Modelos cognitivos e Grafos Temporais oferecem alta precisão, mas impõem alta latência e complexidade de integração. Por outro lado, bancos vetoriais tratam memórias de forma estática, sem versionamento temporal. O gap identificado é a ausência de um padrão arquitetural desacoplado do LLM e pronto para produção. *Alguns dos artigos relevantes se encontram anexo	Metodologia Design Science Research (Peffers et al., 2007).				
Problema/Oportunidade de pesquisa A pesquisa investiga como organizar dados factuais mutáveis no tempo com relevância contextual e recuperabilidade contínua. Busca-se definir arquiteturas de software para criar memórias artificiais com <i>soft decay</i> (decaimento contínuo) e <i>hard updates</i> (invalidação determinística), permitindo dissociar conteúdos de relevância estritamente semântica daqueles que se encontram vigentes dentro do contexto e tempo.	Objetivo da pesquisa O objetivo geral é propor, implementar e avaliar uma Arquitetura de Referência para memórias artificiais temporais em RAG. Os objetivos específicos são: (1) mapear métodos capazes de identificar conflitos na recuperação da informação via MSL; (2) formalizar políticas de decaimento e invalidação; (3) desenvolver protótipo open-source da arquitetura; e (4) avaliar a solução contra baselines em benchmark controlado.	Plano de ação A avaliação experimental compara a proposta a três baselines: Vector RAG Tradicional, GraphRAG Estático e Janela Deslizante, usando métricas como Update Fidelity , Interference Resistance , latência e Precision/Recall@K . A reprodutibilidade emprega modelos open-weight (<i>Ollama/vLLM</i>) e o <i>DRIFTBENCH</i> . O cronograma estrutura-se em quatro marcos: 1) MSL e requisitos arquiteturais; 2) formalização da arquitetura e qualificação; 3) protótipo open-source e testes; e 4) avaliação experimental, entrega da dissertação, e defesa.				
Justificativa & Relevância Estudos como o DRIFTBENCH (Zhang et al., 2024) e Temporal Poisoning (Chen et al., 2024) comprovam a perda de acurácia em RAGs sob atualização contínua. Na prática, frameworks como LangChain e LlamalIndex não possuem gestão de ciclo de vida temporal. A pesquisa eleva a confiabilidade de agentes, reduz custos operacionais e apoia o direito ao esquecimento (LGPD/GDPR).	Solução/Proposição A proposta de solução é uma Arquitetura de Referência Híbrida (Vetores + Grafos + Políticas de Decaimento) independente de LLM, com <i>soft decay</i> e <i>hard updates</i> . Em DSR, abrange quatro artefatos: o constructo de Memória Artificial, o modelo da arquitetura de software, o método dos algoritmos de decaimento/invalidação e a instanciação via protótipo open-source (SDK próprio ou contribuição).	RESULTADOS <table><tr><td>Científicos Formalizar uma Arquitetura de Referência para memórias artificiais em RAG, dotada de mecanismos de decaimento controlado e resolução de conflitos.</td><td>Limitações Aplicação em dados factuais textuais e estruturados, e a avaliação realizada com base em benchmarks sintéticos e controlados.</td></tr><tr><td>Tecnológicos O desenvolvimento de uma biblioteca open-source e de pacotes de extensão para projetos de referência, como LangChain e LlamalIndex.</td><td></td></tr></table>	Científicos Formalizar uma Arquitetura de Referência para memórias artificiais em RAG, dotada de mecanismos de decaimento controlado e resolução de conflitos.	Limitações Aplicação em dados factuais textuais e estruturados, e a avaliação realizada com base em benchmarks sintéticos e controlados.	Tecnológicos O desenvolvimento de uma biblioteca open-source e de pacotes de extensão para projetos de referência, como LangChain e LlamalIndex .	
Científicos Formalizar uma Arquitetura de Referência para memórias artificiais em RAG, dotada de mecanismos de decaimento controlado e resolução de conflitos.	Limitações Aplicação em dados factuais textuais e estruturados, e a avaliação realizada com base em benchmarks sintéticos e controlados.					
Tecnológicos O desenvolvimento de uma biblioteca open-source e de pacotes de extensão para projetos de referência, como LangChain e LlamalIndex .						
FUNDAMENTOS Conceitos A pesquisa fundamenta-se em uma tríade: a área de conhecimento abrange Engenharia de Software, Recuperação de Informação e LLMs; a área problema foca em Temporal Poisoning , Memory Drift , Lost in the Middle e amnésia contextual ; e a área solução articula RAG , Grafos de Conhecimento , Arquitetura de Referência , o modelo cognitivo ACT-R e padrões de projeto de software.		PERSPECTIVAS Gerar impacto tecnológico (arquitetura de referência), econômico (redução de tokens), social (LGPD) e acadêmico (benchmark aberto). Como trabalhos futuros, avaliação da arquitetura contra envenenamento de memória (Memory Poisoning) e expansão para suporte multimodal e dispositivos de borda (Edge AI).				

CONTEXTO E MOTIVAÇÃO

POR QUÊ?

Sistemas de Geração Aumentada por Recuperação (RAG)


O conhecimento é tratado como **atemporal e estático**, priorizando exclusivamente a **similaridade vetorial** por cosseno.

Constatação Empírica

Fatos obsoletos são resgatados conjuntamente com os vigentes quando possuem alta aderência vocabular à consulta.

Consequência: Alucinação temporal, perda de consistência contextual e respostas contraditórias do modelo de linguagem.

Exemplo: Similaridade Semântica vs. Relevância Temporal



Diagnóstico: A proximidade semântica em espaços densos é ortogonal à vigência temporal dos dados.

PROBLEMA E OPORTUNIDADE DE PESQUISA

POR QUÊ?

Problema Central de Pesquisa

Como organizar **dados factuais mutáveis no tempo** garantindo **relevância contextual** e **recuperabilidade contínua**?

Oportunidade Arquitetural

Definir arquiteturas de software para criar memórias artificiais operando sob dois regimes complementares de ciclo de vida factual:

Soft Decay (Decaimento Contínuo)

Atenuação progressiva da ativação e relevância de memórias por tempo decorrido e taxa de desuso.

Hard Updates (Invalidação Determinística)

Invalidação atômica e substituição imediata de declarações factuais revogadas ou em contradição.

JUSTIFICATIVA E RELEVÂNCIA

POR QUÊ?

Justificativa Técnica

A acurácia de sistemas de recuperação de informação degrada severamente quando submetida a fluxos longitudinais de atualização contínua. Fatos obsoletos permanecem como fontes ativas de interferência, exigindo governança do ciclo de vida temporal para evitar alucinações e respostas conflitantes.

Confiabilidade Operacional

Garante integridade contextual e respostas consistentes em agentes autônomos e assistentes corporativos de longa duração.

Eficiência de Recursos

Redução substancial do consumo de tokens e custos de inferência ao expurgar contextos históricos redundantes da janela do LLM.

Conformidade e Esquecimento

Instrumentação técnica auditável para o direito ao esquecimento e descarte atômico de dados pessoais (LGPD/GDPR).

CONCEITOS FUNDAMENTAIS

FUNDAMENTOS

● Área de Conhecimento

- **Engenharia de Software:** Arquiteturas de referência, desacoplamento e padrões.
- **Recuperação de Informação:** Indexação densa e metadados temporais.
- **Modelos de Linguagem:** Grounding factual e prompting condicionado.

● Área Problema

- **Temporal Poisoning:** Contaminação por fatos passados.
- **Memory Drift:** Perda de precisão com novas inserções.
- **Lost in the Middle:** Decaimento atencional em contexto longo.
- **Amnésia Contextual:** Falha de retenção de regras vigentes.

● Área Solução

- **RAG Híbrido:** Busca vetorial conjugada a índices relacionais.
- **Grafos Temporais (TKGs):** Marcação de validade temporal.
- **Modelo ACT-R:** Decaimento de ativação temporal.
- **Arquitetura de Referência:** Padrão reutilizável desacoplado.

Delimitação Epistemológica: O termo "*Memória Artificial*" é empregado de forma **estritamente computacional**, designando estruturas de dados gerenciadas por software com retenção e decaimento temporal, sem pretensão ou analogia neurobiológica.

ESCOPO DELIMITADO

ESTADO DA ARTE E DA PRÁTICA

O QUÊ?

Abordagem Mapeada	Comportamento e Limitações
Bancos Vetoriais (Estado da Prática)	Tratamento atemporal e estático dos dados; ausência de versionamento ou descarte nativo.
Modelos Cognitivos (Estado da Arte)	Fundamentação matemática para decaimento temporal; alta complexidade e sem conectores industriais.
Grafos Temporais (Estado da Arte)	Representação de arestas temporais explícitas; alta latência nas consultas e elevado custo computacional.

Evidências da Literatura Científica Recente

Deriva em Raciocínio Relacional (2025)

Pesquisas recentes comprovam que modelos de linguagem sofrem deriva de memória precoce sob fluxos contínuos de fatos distribuídos ao longo do tempo.

Fidelidade ao Contexto (ACL 2025)

Estudos indicam que delegar a resolução temporal à camada de dados e software eleva substancialmente a fidelidade das respostas geradas pelo modelo.

OBJETIVOS DA PESQUISA

O QUÊ?

OBJETIVO GERAL DA PESQUISA

Propor, implementar e avaliar uma Arquitetura de Referência para memórias artificiais temporais em sistemas RAG, dotada de mecanismos de decaimento contínuo (*soft decay*) e invalidação determinística (*hard updates*), resolvendo conflitos na recuperação da informação.

OE 1 • MAPEAMENTO

Mapear Métodos

Identificar técnicas de detecção e mediação de conflitos temporais via Mapeamento Sistemático da Literatura (MSL).

OE 2 • FORMALIZAÇÃO

Formalizar Políticas

Formalizar matematicamente as regras de *soft decay* (tempo e uso) e de *hard updates* (invalidação atômica).

OE 3 • INSTANCIAÇÃO

Desenvolver Protótipo

Implementar biblioteca open-source em Python com módulos de extensão para LangChain e LlamaIndex.

OE 4 • AVALIAÇÃO

Avaliar em Benchmark

Avaliar a arquitetura contra três baselines em bancada controlada sob o benchmark DRIFTBENCH.

SOLUÇÃO E PROPOSIÇÃO

O QUÊ?

Arquitetura de Referência Híbrida

Solução independente de LLM conjugando **Vetores + Grafos + Políticas Temporais**.

Soft Decay

Atenuação contínua de ativação por recência e frequência de acesso.

Hard Updates

Invalidação determinística e atômica de relações superadas.

Desacoplamento: Governança prévia à injeção no prompt, garantindo escalabilidade e contexto consistente.

1. CONSTRUCTO

Memória Artificial Temporal

Formalização de validade temporal, ciclos de retenção e obsolescência.

2. MODELO

Arquitetura de Referência

Visões estrutural, de dados e de processo para governança de memória.

3. MÉTODO

Algoritmos Operacionais

Rotinas de ativação temporal, poda seletiva e resolução determinística.

4. INSTANCIAÇÃO

Protótipo Open-Source

Biblioteca de código aberto e módulos integráveis a LangChain e LlamaIndex.

METODOLOGIA E AVALIAÇÃO EXPERIMENTAL

COMO?

Metodologia: Design Science Research (DSR)

A pesquisa adota o método de **Design Science Research** (Peppers et al., 2007), voltado à concepção, desenvolvimento e validação empírica de artefatos de software para resolução de problemas reais de engenharia.

Baselines de Comparação

1. **Vector RAG Tradicional:** Indexação por cosseno puro (atemporal).
2. **GraphRAG Estático:** Grafo relacional sem decaimento de arestas.
3. **Janela Deslizante:** Filtro fixo por timestamp (descarte cego).

Métricas de Avaliação Experimental

Update Fidelity

Resgate do fato
vigente mais recente.

Interference Res.

Supressão de fatos
caducos.

Eficiência

Latência, tokens e P/
R@K.

Reprodutibilidade e Bancada de Testes

Execução com modelos *open-weight* locais (Ollama / vLLM) e dataset aberto **DRIFTBENCH** (Zhang et al., 2024), assegurando rigor, controle de hiperparâmetros e replicação científica.

Critérios de Rigor (Pimentel et al., 2017): Critério de Aceitação (desacoplamento) e Critério de Verificação (superioridade empírica).

CRONOGRAMA DE ATIVIDADES

COMO?

Marco 1

MSL & Requisitos

- Execução do MSL.
- Elicitação de requisitos.
- Artigo do estado da arte.

Marco 2

Formalização & Qualificação

- Modelagem formal da arquitetura e políticas.
- Preparação para qualificação.
- Exame de Qualificação.

Marco 3

Instanciação & Testes

- Implementação da biblioteca.
- Pacotes de extensão LangChain/LlamaIndex.
- Testes e experimentos.

Marco 4

Avaliação & Defesa

- Avaliação em benchmarks.
- Análise e discussão dos resultados.
- Defesa da Dissertação.

RESULTADOS ESPERADOS E LIMITAÇÕES

RESULTADOS

Resultados Científicos

ACADÊMICO

- Formalização da **Arquitetura de Referência** para memórias temporais em RAG.
- Modelos matemáticos de **soft decay** e **invalidação determinística**.

Resultados Tecnológicos

INDÚSTRIA

- **Biblioteca Open-Source** em Python, modular e desacoplada.
- **Conectores** para ecossistemas de referência (LangChain, LlamalIndex).

Escopo de Dados Factuais

Restrito estritamente a **dados textuais e estruturados**. Dados multimodais permanecem fora do escopo.

Ambiente Experimental

Avaliação em **benchmarks sintéticos e controlados** para assegurar mensuração causal exata e reprodutibilidade aberta.

PERSPECTIVAS E IMPACTOS

PERSPECTIVAS

Tecnológico

Padrão arquitetural reutilizável para a indústria de software corporativo.

Econômico

Redução substancial de tokens ao expurgar contextos obsoletos.

Social / LGPD

Instrumentação auditável para o direito ao esquecimento.

Acadêmico

Benchmark aberto para avançar pesquisas em ES para IA.

OPORTUNIDADE EM TRABALHOS FUTUROS

Segurança & Memory Poisoning

Resiliência contra injeções adversariais maliciosas na base de memória.

Multimodalidade & Edge AI

Expansão para dados visuais e execução em dispositivos na borda.

OBRIGADO